

# Sistemi Digitali M

## Progetto SuperSlowMoApp

Filippo Lenzi

Guglielmo Palaferri

12 luglio 2022

# Introduzione

Questo progetto è ispirato ad un lavoro del 2018 intitolato “*Super SloMo: High Quality Estimation of Multiple Intermediate Frames for Video Interpolation*” (disponibile a questo link). Tale studio illustra l’uso di *reti neurali convoluzionali* (CNN) per svolgere l’*interpolazione dei frame* in un video.

Lo scopo del progetto era quello di realizzare un’applicazione Android che implementasse un sistema di slow motion “artificiale” tramite le tecniche esposte nell’articolo sopra citato. In particolare, è stata utilizzata un’implementazione del modello in Pytorch disponibile su GitHub, la quale è stata adattata per l’utilizzo su un dispositivo Android.

## Interpolazione dei frame

Una delle tecniche tradizionali per realizzare video in slow-motion risiede nell’utilizzo di telecamere capaci di registrare video a framerate elevati, ad esempio 240 fps (tuttavia in casi con esigenze particolari si possono raggiungere anche decine di migliaia di fps). In questo modo è possibile poi rallentare il video, riproducendolo ad un framerate più basso (tipicamente 25-30 fps) e ottenendo quindi un effetto slow-motion.

Nel contesto dei dispositivi embedded, tuttavia, può essere impossibile equipaggiare telecamere di questo tipo (per via dei costi o delle dimensioni). In questi casi risulta utile disporre di strategie alternative, come l’interpolazione dei frame. Questa tecnica, applicata ad un video pre-registrato, mira a generare artificialmente uno o più fotogrammi intermedi a partire da due fotogrammi consecutivi, al fine di aumentare il framerate del video e consentire di riprodurlo in slow-motion successivamente mantenendone la fluidità. Ovviamente, questo metodo garantisce una precisione molto inferiore rispetto all’utilizzo di telecamere ad alta velocità, essendo i frame aggiuntivi ottenuti tramite una stima e non effettivamente catturati dalla telecamera.

L’interpolazione dei frame può essere implementata in diversi modi, l’implementazione che verrà utilizzata in questo progetto è basata su reti neurali convoluzionali, come già anticipato. Di seguito un confronto dei risultati ottenuti con diverse implementazioni, estratto dal paper di riferimento.




Figura 1: (a) frame intermedio originale; risultati di interpolazione con: (b-e) diverse implementazioni, (f) implementazione di riferimento. Fonte: <https://arxiv.org/abs/1712.00080>

Introduciamo brevemente il concetto delle reti neurali convoluzionali, che comunque viene toccato molto marginalmente dal progetto (ci si limita ad utilizzare un modello prefatto).

## Reti neurali convoluzionali (CNN)

Una rete neurale può essere definita come una sequenza di *layer*, ciascuno di essi formato da un'insieme di nodi (anche detti neuroni) interconnessi tra loro. Ogni nodo è rappresentato da un peso e riceve in input un valore da ciascun nodo del layer precedente. Una funzione di attivazione determina lo stato di ciascun nodo: se il nodo è attivo, fornisce un input ai nodi del layer successivo. L'output di ciascun nodo dipende dagli input e dai pesi dei nodi precedenti.




Figura 2: Rappresentazione grafica di una rete neurale

I pesi dei nodi della rete vengono assegnati secondo un processo chiamato *addestramento*: vengono dati in pasto alla rete degli input preselezionati, lasciando che i pesi iniziali (con valori casuali) forniscano l'output. I valori dei pesi vengono poi aggiustati con l'obiettivo di minimizzare la differenza tra l'output fornito dalla rete e l'output atteso, secondo un processo chiamato *backpropagation*.

Le *reti neurali convoluzionali* (CNN) sono un particolare tipo di rete neurale che trova ampio utilizzo nell'ambito della computer vision e del processamento di immagini. Esse sono composte da tre tipi principali di layer:

- Layer di Convoluzione: primo layer della rete. Può essere seguito da un layer di convoluzione o uno di pooling. In questi layer viene applicata la convoluzione: un filtro 2D (detto **kernel**) viene applicato all'immagine di input
- Layer di Pooling: layer intermedio (può non essere presente)
- Layer Fully-Connected (FC): layer finale, è l'unico in cui ciascun nodo è collegato direttamente ai nodi del layer precedente

Nei layer iniziali della rete viene applicata la convoluzione: un filtro 2D (**kernel**) viene passato sull'immagine di input. L'output è di dimensioni minori dell'input e viene detto anche *feature map*, poiché indica la distribuzione di determinate caratteristiche nell'immagine. Le caratteristiche estratte sono strettamente legate al tipo di filtro utilizzato. I layer di pooling svolgono una funzione di aggregazione dell'input, approssimando un insieme di valori adiacenti della feature map ad un singolo valore (utilizzando un altro tipo di kernel).

La rete quindi diminuisce progressivamente le dimensioni dell'immagine di input, arrivando ad esprimere in output, ad esempio, una probabilità. Spesso infatti, le CNN vengono utilizzate per problemi di classificazioni di immagini. Tuttavia, come vedremo brevemente, il modello che abbiamo qui utilizzato risulta più complicato e produce un diverso tipo di output, non essendo adibito alla classificazione di immagini.

Nel successivo capitolo si procede a descrivere brevemente il modello Pytorch utilizzato, alcune sue caratteristiche e il processo di conversione necessario per l'utilizzo su dispositivo Android.

# Capitolo 1

## Conversione del modello

### 1.1 Spiegazione rapida del modello originale

Il modello esposto nel paper di riferimento è in realtà la combinazione di due CNN. Queste due reti vengono denominate “Flow computation” e “Flow interpolation”. Entrambe le reti sono basate su un’architettura detta *U-Net*, che descrive una CNN formata da un encoder ed un decoder, entrambi composti da una gerarchia di diversi layer convoluzionali e di pooling. Entrambe le U-Net utilizzate hanno un encoder di 6 layer ed un decoder di 5 layer.

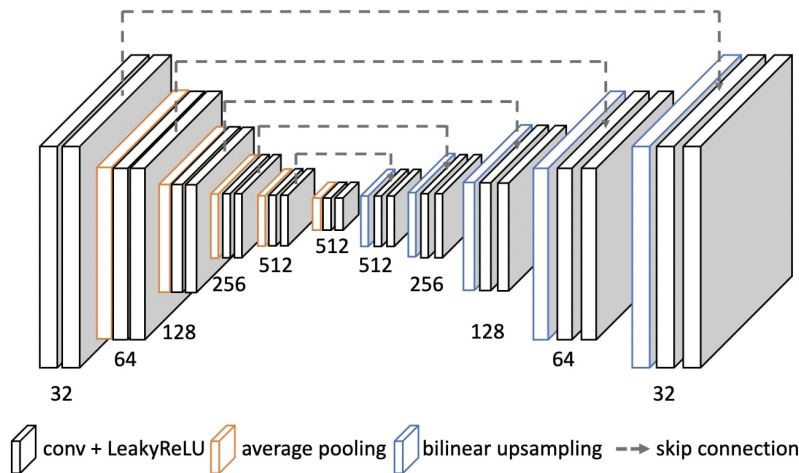


Figura 1.1: Illustrazione dell’architettura delle CNN Flow computation e Flow interpolation. Fonte: <https://arxiv.org/abs/1712.00080>

Date due immagini  $I_0$  e  $I_1$  in input, l’obiettivo della rete è di stimare quale dovrebbe essere il flusso ottico tra il frame intermedio  $I_t$  (non ancora generato) e le due immagini  $I_0$  e  $I_1$ . Una volta completata la stima, l’interpolazione (quindi la sintesi del nuovo frame) viene effettuata sulla base del flusso ottico mediante metodi algebrici descritti nel paper.

Il funzionamento della rete nel dettaglio non viene qui riportato, poiché risulta molto complesso e va oltre gli scopi del seguente progetto.

### 1.2 PyTorch e PyTorch Mobile

PyTorch è uno dei due framework di machine learning più popolari. Esso è sviluppato da Facebook (ora Meta), ed è basato su Python.

Il workflow del framework si può riassumere in questo modo:

- Caricare i dati di training e test, come `Dataset`, incapsulati poi dentro ad un `Dataloader` per permettere l'iterazione.
- Creazione di un modello, definendo i vari layer della rete neurale usando delle funzioni incorporate nel framework, dentro ad una classe `nn.Module`.
- Training, ripetendo delle iterazioni sul dataloader nelle quali si computa l'errore di predizione, e in base a esso si calcolano i nuovi pesi, per poi verificare il miglioramento dell'accuratezza tramite il dataset di test.
- Uso dei modelli così allenati caricando i pesi e usando la stessa classe `Module` creata in precedenza, in modalità *no\_grad* per differenziare dallo stato di training (impedendo così la modifica dei pesi), e ottenendo così delle predizioni.

PyTorch normalmente gestisce dati in forma di tensori, e offre funzioni di libreria per convertire tipi di dato comune da e a tensori, in particolare, per lo scopo di questo progetto, permette di convertire immagini in tensori e vice versa.

### 1.2.1 PyTorch Mobile

PyTorch Mobile è un runtime per PyTorch su dispositivi mobile e embedded, al momento in beta. Supporta i sistemi operativi iOS, Android, e Linux, offrendo API per le operazioni di uso comune necessarie a integrare le reti neurali in questo genere di applicazioni, oltre a supportare operazioni di ottimizzazione come la quantizzazione. Offre anche un interprete ottimizzato per PyTorch su Android e iOS, che compila selettivamente solo le componenti del framework necessarie all'app.

Si può anche sfruttare TorchScript per migliorare e facilitare l'ottimizzazione di modelli a dispositivi mobile. TorchScript è un linguaggio creato ad hoc per PyTorch, ed è una sottoparte del linguaggio Python, in particolare delle parti necessarie a rappresentare reti neurali. Inoltre, TorchScript ha tipi delle variabili statici, a differenza di Python.

PyTorch offre funzioni per compilare codice Python in TorchScript, sottostando a certi vincoli. Per esempio, `torch.jit.script` permette di trasformare `Module` o funzioni in `ScriptModule` e `ScriptFunction`, delle copie dell'originale convertite in TorchScript, che poi potranno essere salvati tramite `torch.jit.save` su file. In particolare, gli `ScriptModule` avranno gli stessi parametri del modello originale, che verranno salvati su file insieme al modello, permettendo quindi di caricare successivamente sia la logica che i parametri allenati del modello dallo stesso file.

PyTorch Mobile sfrutta TorchScript per permettere di caricare il modello sul framework e nel linguaggio di destinazione (per esempio, Java o Kotlin per Android). Questo permette di creare il modello usando l'API di PyTorch in Python, senza dover "ricreare" il codice Python del modello originale in Java o altri linguaggi. Di conseguenza, l'API di PyTorch Mobile per Android è molto minimale, offrendo funzioni per caricare modelli di TorchScript, wrapper per tensori e modelli, e un wrapper generico ai tipi di TorchScript, `IValue`.

L'API non offre funzioni equivalenti alla maggior parte dei metodi di libreria PyTorch, supponendo che l'utente usi direttamente le funzioni in Python e le carichi nell'applicazione convertite in formato TorchScript; l'API Mobile è quindi generalmente disaccoppiata dalla libreria di Pytorch.

Il workflow generale per convertire modelli a PyTorch Mobile è descritto nella figura 1.2. Una volta ottenuto il modello convertito, e trasformati i dati in `IValue` tensori nell'API del sistema di destinazione, si chiama il metodo `forward` del modello convertito per ottenere la propria predizione.

Una nota importante è il diverso formato dei modelli TorchScript ottimizzati per mobile: essi vengono salvati tramite la funzione interna alla classe `ScriptModule` `_save_for_lite_interpreter`, in un formato diverso rispetto a quelli salvati tramite `torch.jit.script`, come si evince dall'estensione suggerita dalla documentazione `.ptl` invece di `.pt`. Nella versione attuale di PyTorch Mobile, esistono due versioni diverse della libreria (per Android, `org.pytorch.pytorch_android` e `org.pytorch.pytorch_android_lite`): ogni versione è in grado di caricare solo i file TorchScript salvati dalla funzione corrispondente, e non l'altra; questo al momento offre problemi per la conversione di funzioni convertite a `ScriptFunction`, che attualmente non dispone di un metodo `_save_for_lite_interpreter`, impedendo quindi di caricare funzioni convertite a TorchScript in un contesto *lite*. Quindi, l'unico modo di usare le varie funzioni di libreria di PyTorch all'interno di applicazioni mobile, nella versione attuale, è usarle all'interno di un `Module` di rete neurale.

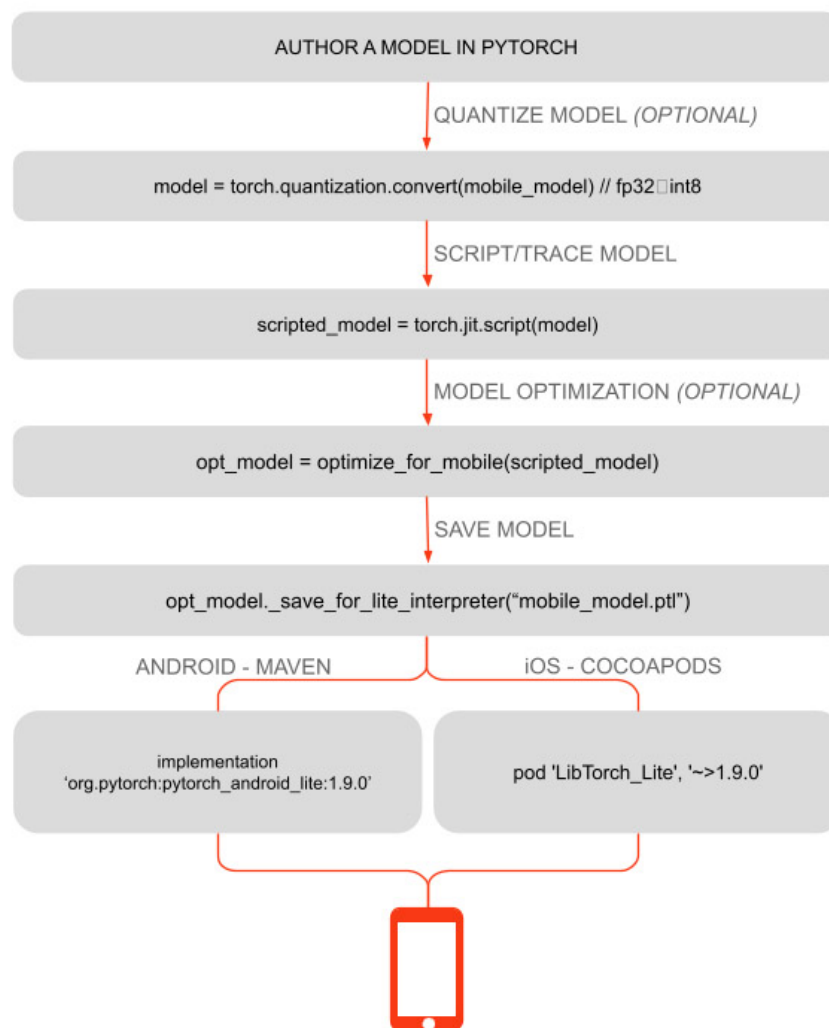


Figura 1.2: Fonte dell'immagine: <https://pytorch.org/mobile/home/>

### 1.2.2 Compensazione di lacune nell'API Mobile

Come detto sopra, l'API di PyTorch Mobile, almeno su Android, è molto essenziale, assumendo che l'utente farà il grosso della logica del modello in Python tramite PyTorch, per poi convertirlo in TorchScript e caricarlo. Mancano quindi i vari metodi per manipolare tensori, e gestire i set di dati, e nella versione attuale di PyTorch Mobile, come sopra, non è possibile caricare funzioni

TorchScript in un contesto di PyTorch Mobile lite. Nel caso in cui servano nell'applicazione funzionalità della libreria PyTorch all'esterno di un modello, sarà necessario reimplementarle.

## Dataset

In questo progetto è stato scelto di reimplementare la classe Pytorch Dataset, nel caso specifico di interesse al progetto, vale a dire un set di immagini rappresentanti fotogrammi di un video, da caricare a due a due in ogni iterazione per interpolare i fotogrammi tra esse. Questo permette di riprodurre il comportamento dell'implementazione originale di SuperSlowMo in Python, usando un codice molto simile.

È stata quindi creata una classe `VideoDataset`, che implementa un'interfaccia `IDataset`, definite in maniera sintetica in seguito:

```
public interface IDataset<T> extends Iterable<T> {
    public abstract T get(int index);
    public abstract int len();
}

public class VideoDataset<T> extends Dataset<Pair<T, T>> {
    private IImageLoader imageLoader;
    private String root;
    private String[] framePaths;
    private Function<Bitmap, T> transform;
    private Size origDim;
    private Size dim;

    public static <T> VideoDataset<T> withRootPath(String root,
        Function<Bitmap, T> transform) {...}
    public static <T> VideoDataset<T> withContextAssets(Context context,
        String root, Function<Bitmap, T> transform) {...}

    [...]
}
```

`VideoDataset` viene creata a partire da set di immagini (specificati o fornendo una cartella nel file system Android, oppure una cartella negli asset dell'applicazione), e permette di fornire una funzione `Transform` che funziona in modo analogo all'argomento *transform* della classe `Dataset` di PyTorch: se presente, viene applicata su ogni immagine durante l'iterazione del dataset, trasformandola in un tipo di dato diverso prima dell'elaborazione.

Un uso comune di questa funzionalità è convertire immagini (classe `Bitmap` in Android) in tensori, quindi `IValue` di tipo `Tensor` nell'API PyTorch Mobile; l'API offre una funzione per questa conversione, `TensorImageUtils.bitmapToFloat32Tensor`. Un esempio di uso con `VideoDataset` è il seguente:

```
videoFrames = VideoDataset.withRootPath(
    framesDir,
    bitmap -> TensorImageUtils.bitmapToFloat32Tensor(bitmap,
        TensorImageUtils.TORCHVISION_NORM_MEAN_RGB,
        TensorImageUtils.TORCHVISION_NORM_STD_RGB
    )
);
```

Ultimo punto importante riguardo a questa classe: in PyTorch, `Dataset` per video ridimensiona le immagini caricate in modo che abbiamo valori di dimensione multipli di 32: per esempio, da (320, 180) a (320, 160). È stato riprodotto questo comportamento in `VideoDataset`, ed è stato rilevante in fase di conversione del modello a mobile (vedi 1.3.2).



## Concatenazione Tensori

Mancando le funzioni di PyTorch per svolgere operazioni tra Tensori, in particolare `torch.cat`, in una prima versione del progetto era stato necessario reimplementare questa funzione in Java. Non viene riportato il codice data la lunghezza, dovendo gestire separatamente i diversi casi di tipi primitivi contenuti dentro al tensore a causa della rigida gestione degli array da parte di Java.

Nelle versioni successive del progetto, è stato possibile spostare tutto il codice che necessitava di operazioni su tensori dentro al modello convertito in TorchScript, evitando la necessità di reimplementare questa funzione.

## Conversione da Tensori a Bitmap

Come sopra, PyTorch Mobile offre una funzione per convertire immagini, quindi la classe `Bitmap` nell'API Android, vale a dire `TensorImageUtils.bitmapToFloat32Tensor`, e alcune funzioni analoghe per altri tipi di dato del tensore. Notevolmente, nella versione attuale al momento dello sviluppo di questo progetto manca una funzione per la conversione nella direzione opposta, vale a dire da tensore a immagine, cosa necessaria per reti neurali che producono immagini come output, come questa.

È stato quindi necessario riprodurre questa funzionalità:

```
public static Bitmap bitmapFromRGBImageAsFloatArray(float[] data,
    int width, int height) {...}
```

Una prima versione portava a gravi artefatti nella conversione dello spazio RGB, che distorcevano le aree più luminose dell'immagine; la seconda versione, quella attuale, tiene conto della media e della deviazione standard dello spazio RGB di interesse in fase di conversione, usando i valori forniti dall'API PyTorch Mobile, `TORCHVISION_NORM_MEAN_RGB` e `TORCHVISION_NORM_STD_RGB`. Un esempio di questo artefatto è in figura 1.3.



Figura 1.3: Errore nella conversione  $\text{tensore} \rightarrow \text{bitmap}$ . A sinistra la prima versione, a destra la versione corretta. Si noti la distorsione nelle aree luminose e le leggere differenze nella temperatura del colore.

## 1.3 Adattamento del modello a Pytorch Mobile

Per adattare il modello di Super SlowMo a Pytorch Mobile innanzitutto è stato necessario convertire il codice di Python del modello originale in Torchscript. Come spiegato nella sezione precedente, PyTorch Mobile è pensato per scrivere la maggior parte della componente logica del modello direttamente in Python, per poi convertire la classe che estende `nn.Module` in Torchscript e esportarla nel dispositivo mobile, soprattutto non disponendo l'API Java di diverse delle funzioni necessarie per il funzionamento del sistema.

### 1.3.1 Struttura del sistema di partenza

Le porzioni di codice seguenti estrometteranno le informazioni non essenziali.

#### Modello

Il codice di Super SlowMo, seguendo il paper originale, usa tre diversi modelli PyTorch: `flowComp`, `ArbTimeFlowIntrp`, e `flowBackWarp`.

---

```
# Initialize model
flowComp = model.UNet(6, 4)
ArbTimeFlowIntrp = model.UNet(20, 5)
flowBackWarp = model.backWarp(videoFrames.dim[0], videoFrames.dim[1],
                                device)
```

---

Si noti come `flowBackWarp` è creata con la stessa dimensione dei fotogrammi in ingresso. Queste sono istanze di classi `Module` complesse così definite:

---

```
class UNet(nn.Module):
    """
    A class for creating UNet like architecture as specified by
    the Super SloMo paper.
    """

    def __init__(self, inChannels, outChannels):
        [...]
        # Initialize neural network blocks.
        self.conv1 = nn.Conv2d(inChannels, 32, 7, stride=1, padding=3)
        self.conv2 = nn.Conv2d(32, 32, 7, stride=1, padding=3)
        self.down1 = down(32, 64, 5)
        self.down2 = down(64, 128, 3)
        self.down3 = down(128, 256, 3)
        self.down4 = down(256, 512, 3)
        self.down5 = down(512, 512, 3)
        self.up1 = up(512, 512)
        self.up2 = up(512, 256)
        self.up3 = up(256, 128)
        self.up4 = up(128, 64)
        self.up5 = up(64, 32)
        self.conv3 = nn.Conv2d(32, outChannels, 3, stride=1, padding=1)

    def forward(self, x):
        # Forward non riportato per ragioni di spazio, applica
        # i sotto-moduli creati sopra preceduti da due funzioni
        # ReLU e seguiti da una ulteriore funzione ReLU.

class backWarp(nn.Module):
    """
    A class for creating a backwarping object.
```

---

This is used for backwarping to an image:

Given optical flow from frame I0 to I1 --> F\_0\_1  
and frame I1, it generates I0 <-- backwarp(F\_0\_1, I1).  
"""

```
def __init__(self, W, H, device):
    [...]
    # create a grid
    gridX, gridY = np.meshgrid(np.arange(W), np.arange(H))
    self.W = W
    self.H = H
    self.gridX = torch.tensor(gridX, requires_grad=False, device=device)
    self.gridY = torch.tensor(gridY, requires_grad=False, device=device)

def forward(self, img, flow):
    # Extract horizontal and vertical flows.
    u = flow[:, 0, :, :]
    v = flow[:, 1, :, :]
    x = self.gridX.unsqueeze(0).expand_as(u).float() + u
    y = self.gridY.unsqueeze(0).expand_as(v).float() + v
    # range -1 to 1
    x = 2*(x/self.W - 0.5)
    y = 2*(y/self.H - 0.5)
    # stacking X and Y
    grid = torch.stack((x,y), dim=3)
    # Sample pixels using bilinear interpolation.
    imgOut = torch.nn.functional.grid_sample(img, grid)
    return imgOut
```

---

up e down sono altri due moduli del sistema non riportati per ragioni di spazio, riassunti dalla documentazione in questo modo:

down:

A class for creating neural network blocks containing layers:  
Average Pooling --> Convolution + Leaky ReLU --> Convolution + Leaky ReLU  
This is used in the UNet Class to create a UNet like NN architecture.

up:

A class for creating neural network blocks containing layers:  
Bilinear interpolation --> Convolution + Leaky ReLU --> Convolution + Leaky ReLU  
This is used in the UNet Class to create a UNet like NN architecture.

## Valutazione

Il codice per la valutazione è contenuto nello script python *video\_to\_slomo.py*. Prima di tutto estrae i fotogrammi dal video tramite Ffmpeg, un diffuso programma per la conversione di file media. Carica poi i fotogrammi tramite un DataLoader:

```
# transform trasforma le immagini in tensori
videoFrames = dataloader.Video(root=extractionPath, transform=transform)
videoFramesloader = torch.utils.data.DataLoader(videoFrames,
    batch_size=args.batch_size, shuffle=False)
```

---

Successivamente, itera sui fotogrammi presi a coppie tramite il DataLoader, interpolando i fotogrammi intermedi tramite i modelli creati in precedenza:

```
for _, (frame0, frame1) in enumerate(tqdm(videoFramesloader), 0):
    I0 = frame0.to(device)
```

```

I1 = frame1.to(device)

flowOut = flowComp(torch.cat((I0, I1), dim=1))
F_0_1 = flowOut[:, :2, :, :]
F_1_0 = flowOut[:, 2:, :, :]

# Save reference frames in output folder
for batchIndex in range(args.batch_size):
    (TP(frame0[batchIndex].detach())).resize(videoFrames.origDim,
        Image.BILINEAR).save(os.path.join(outputPath, str(frameCounter +
            args.sf * batchIndex) + ".png"))
frameCounter += 1

# Generate intermediate frames
for intermediateIndex in range(1, args.sf):
    t = float(intermediateIndex) / args.sf
    temp = -t * (1 - t)
    fCoeff = [temp, t * t, (1 - t) * (1 - t), temp]

    F_t_0 = fCoeff[0] * F_0_1 + fCoeff[1] * F_1_0
    F_t_1 = fCoeff[2] * F_0_1 + fCoeff[3] * F_1_0

    g_I0_F_t_0 = flowBackWarp(I0, F_t_0)
    g_I1_F_t_1 = flowBackWarp(I1, F_t_1)

    intrpOut = ArbTimeFlowIntrp(torch.cat((I0, I1, F_0_1, F_1_0, F_t_1,
        F_t_0, g_I1_F_t_1, g_I0_F_t_0), dim=1))

    F_t_0_f = intrpOut[:, :2, :, :] + F_t_0
    F_t_1_f = intrpOut[:, 2:4, :, :] + F_t_1
    V_t_0 = torch.sigmoid(intrpOut[:, 4:5, :, :])
    V_t_1 = 1 - V_t_0

    g_I0_F_t_0_f = flowBackWarp(I0, F_t_0_f)
    g_I1_F_t_1_f = flowBackWarp(I1, F_t_1_f)

    wCoeff = [1 - t, t]

    Ft_p = (wCoeff[0] * V_t_0 * g_I0_F_t_0_f + wCoeff[1] * V_t_1 *
        g_I1_F_t_1_f) / (wCoeff[0] * V_t_0 + wCoeff[1] * V_t_1)

# Save intermediate frame
for batchIndex in range(args.batch_size):
    (TP(Ft_p[batchIndex].cpu().detach())).resize(videoFrames.origDim,
        Image.BILINEAR).save(os.path.join(outputPath,
            str(frameCounter + args.sf * batchIndex) + ".png"))
frameCounter += 1

# Set counter accounting for batching of frames
frameCounter += args.sf * (args.batch_size - 1)

```

---

L'operazione è piuttosto complessa, e la quantità di fotogrammi generata dipende da *args.sf*, lo *scale factor*, vale a dire il moltiplicatore (intero) della quantità di fotogrammi del video finale a partire dall'originale. Per esempio, partendo da un video a 30 fotogrammi per secondo, uno scale factor di 3 porterebbe a un video finale di 90 fotogrammi per secondo con la stessa durata, oppure ad un video finale di 30 fotogrammi per secondo ma lungo  $\frac{1}{3}$  del video originale.

### 1.3.2 Adattamento

Per adattare il complesso script di conversione e modello a PyTorch Mobile, è stato seguito il workflow consigliato per questo runtime, facendo in modo di apporre meno modifiche possibili al modello, per evitare possibili imprevisti sia data la sua complessità, sia dato lo stato ancora in sviluppo di PyTorch Mobile.

#### Adattamento del modello

Il modello è stato, come da workflow standard di PyTorch Mobile, convertito in TorchScript e salvato su file per poterlo successivamente usare nell'applicazione Android. Una prima versione si limitava a creare istanze delle classi del sistema, convertirle in TorchScript dopo aver caricato i dati del modello pre-allenato disponibile sul repository del sistema originale, e salvarle su file, in questo modo:

---

```
# ckpt: percorso file di checkpoint contenente
# i parametri post-training
dict1 = torch.load(ckpt, map_location='cpu')
flowComp = model.UNet(6, 4)
flowComp.load_state_dict(dict1['state_dictFC'])
flowComp_ts = torch.jit.script(flowComp)
flowComp_opt = optimize_for_mobile(flowComp_ts)
flowComp_opt._save_for_lite_interpreter('flowComp.ptl')
```

---

Il procedimento ha funzionato, dopo delle minori correzioni necessarie data la staticità dei tipi di TorchScript a differenza di Python, che portavano al fallimento della compilazione a causa di righe come

---

```
x = F.interpolate(x, scale_factor=2, mode='bilinear')
```

---

dentro al modulo `up`, dove `scale_factor` richiede un dato di tipo *float*, ma riceve un *int*, cioè 2, come valore. Ovviamente questa riga è perfettamente valida in Python, che non differenzia neanche interi o float oltre a non avere questo genere di controlli di tipo, ma non in TorchScript che appunto è un linguaggio a tipi statici.

Questa prima versione della conversione, però, per i problemi citati precedentemente nell'uso di funzioni di PyTorch al di fuori di un modulo rendeva difficile implementare la parte di valutazione che usava i modelli senza reimplementare diverse parti della libreria di PyTorch: quindi, si ha optato per un approccio più vicino all'uso inteso del runtime Mobile, cioè di includere quanto possibile delle parti di codice riguardanti PyTorch all'interno dei moduli.

Sono state quindi create due classi wrapper: `FlowCompCat`, che incapsula il codice di valutazione eseguito prima di iterare su ogni fotogramma intermedio da interpolare, e `FrameInterpolation`, che genera i fotogrammi intermedi (corrispondente al codice che segue `for intermediateIndex in range(1, args.sf)` nel codice di valutazione originale).

---

```
class FlowCompCat(nn.Module):
    def __init__(self) -> None:
        self.flowComp = model.UNet(6, 4)

    def forward(self, t1, t2):
        flowOut = self.flowComp(torch.cat((t1, t2), dim=1))
        F_0_1 = flowOut[:, :2, :, :]
        F_1_0 = flowOut[:, 2:, :, :]

        return (F_0_1, F_1_0)

# Override di load_state_dict per caricare i dati del
# checkpoint dentro al modulo di flowComp interno,
```

---

```

# per cui sono stati creati
def load_state_dict(self, state_dict: 'OrderedDict[str, Tensor]',
                    strict: bool = True):
    return self.flowComp.load_state_dict(state_dict, strict)

class FrameInterpolation(nn.Module):
    def __init__(self, sizex, sizey) -> None:
        self.flowBackWarp = model.backWarp(sizex, sizey, 'cpu')
        self.ArbTimeFlowIntrp = model.UNet(20, 5)

    def forward(self, t: float, I0, I1, F_0_1, F_1_0):
        temp = -t * (1 - t)
        [...]
        # Codice corrispondente all'interno del loop nel codice
        # di valutazione originale, fino all'assegnamento di Ft_p
        [...]

        return (wCoeff[0] * V_t_0 * g_I0_F_t_0_f + wCoeff[1] * V_t_1 *
                g_I1_F_t_1_f) / (wCoeff[0] * V_t_0 + wCoeff[1] * V_t_1)

    def load_state_dict(self, state_dict: 'OrderedDict[str, Tensor]',
                        strict: bool = True):
        return self.ArbTimeFlowIntrp.load_state_dict(state_dict, strict)

```

---

Questi moduli vengono poi convertiti a TorchScript, ottimizzati per l'interprete lite, e salvati su file come i precedenti.

Si noti come `FrameInterpolation`, che contiene al suo interno `flowBackWarp`, necessita come esso di ricevere dall'esterno la dimensione dei fotogrammi. Questo ha creato una ulteriore problematica nel convertire i modelli: infatti, mentre eseguendo lo script Python l'oggetto del modulo `flowBackWarp` viene creato al momento, con parametri passati ad hoc in base ai fotogrammi caricati durante l'esecuzione, i parametri del modulo da esportare per PyTorch Mobile sono impostati prima della creazione del modulo da salvare, e una volta salvato su file rimangono costanti. Non è un problema per gli altri due moduli, che sono creati con valori costanti per parametri.

Per ovviare al problema, è stato necessario esportare un modulo diverso per ogni combinazione di risoluzioni: questo mette già un primo vincolo all'applicazione mobile non presente nel modello originale, vale a dire la possibilità di scegliere solo tra una limitata gamma di risoluzioni di output.

Inoltre, dato il funzionamento dei Dataset, le immagini in elaborazione vengono ridimensionate a dimensioni multiple di 32 (vedi 1.2.2); quindi le dimensioni preimpostate usate per la generazione dei moduli da caricare saranno assegnate a uno di questi valori.

```

flowBackwarpResolutions = [
    (1280, 704),
    (320, 160),
]
flowBackWarps = {}

for res in flowBackwarpResolutions:
    key = f"frameInterp_{res[0]}x{res[1]}"
    flowBackWarps[key] = mobile_model.FrameInterpolation(res[0], res[1])
    flowBackWarps[key] = flowBackWarps[key].to(device)
    flowBackWarps[key].eval()
    flowBackWarps[key].load_state_dict(dict1['state_dictAT'])

```

---

### 1.3.3 Valutazione

La valutazione, essendo eseguita dall'applicazione stessa, è realizzata in Java tramite le API di Android e PyTorch. Viene usata la classe `VideoDataset` mostrata in precedenza (vedi 1.2.2) per emulare il caricamento dei fotogrammi dello script originale:

```
videoFrames =
    VideoDataset.withRootPath(extractedFramesDir.getAbsolutePath(), bitmap ->
        TensorImageUtils.bitmapToFloat32Tensor(bitmap,
            TensorImageUtils.TORCHVISION_NORM_MEAN_RGB,
            TensorImageUtils.TORCHVISION_NORM_STD_RGB
        )
    );
```

È poi stata realizzata una classe `SlowMo`, contenente il *core business* della valutazione. Riceve dall'esterno il dataset, i moduli caricati da file, lo scale factor, un oggetto *ImageWriter* e parametri opzionali come un handler degli aggiornamenti del progresso dell'operazione (per poterli mostrare sull'app) ed eventuali funzioni di log.

Anche `ImageWriter` è una classe dell'applicazione, usata per sostituire la creazione di file di fotogrammi con eventuali funzioni mock, nel caso sia necessario in fase di test.

```
slowMoEvaluator = new SlowMo()
    .scaleFactor(scaleFactor)
    .videoFrames(videoFrames)
    .flowCompCat(flowCompCat)
    .frameInterp(frameInterp)
    .imageWriter(new ImageWriter(convertedFramesDir.getAbsolutePath()));
```

Al suo interno, `SlowMo` ha una logica analoga a quella dello script *video\_to\_slomo.py* di partenza:

```
int iter = 0;
int frameCounter = 1;
float progressIncrements = 1 / (float) videoFrames.len();
progress = 0;

for (Pair<Tensor, Tensor> sample : videoFrames) {
    IValue I0 = IValue.from(sample.first), I1 = IValue.from(sample.second);
    IValue[] flowOutTuple = flowCompCat.forward(I0, I1).toTuple();
    IValue I_F_0_1 = flowOutTuple[0], I_F_1_0 = flowOutTuple[1];

    // Save reference frames as image
    resizeAndSaveFrame(frameCounter, sample.first);

    frameCounter++;

    for (int intermediateIndex = 1; intermediateIndex < scaleFactor;
        intermediateIndex++) {
        double t = intermediateIndex / (double) scaleFactor;
        IValue I_t = IValue.from(t);

        IValue I_Ft_p = frameInterp.forward(
            I_t,
            I0,
            I1,
            I_F_0_1,
            I_F_1_0
        );
        Tensor Ft_p = I_Ft_p.toTensor();

        // Save interpolated frame as image
```



```

        resizeAndSaveFrame( frameCounter , Ft_p);

        frameCounter++;
    }

    progress += Math.min(progressIncrements , 1f);
    publish(progress);
}

```

Quindi: per ogni coppia di fotogrammi, viene fatta un’elaborazione preliminare con `flowCompCat`, e poi per ogni nuovo fotogramma la maggior parte del lavoro è svolto da `frameInterp`, che crea il tensore corrispondente alla nuova immagine; esso viene a sua volta convertito in `Bitmap`, scalato alla dimensione originale (per ovviare al già citato ridimensionamento in multipli di 32 compiuto da `Dataset`), e salvato come immagine.

### 1.3.4 Limiti

Il modello così adattato a mobile, per quanto ben più ottimizzato dell’originale grazie a PyTorch Mobile e alle sue funzioni di ottimizzazione, rimane un software molto pesante per dispositivi mobili. La versione attuale è stata testata su video a 180p (cioè, di dimensione pari a 320x180 pixel, sia verticali che orizzontali), ma con dimensioni non troppo superiori fallisce nell’esecuzione a causa della mancanza di memoria. Inoltre, i tempi di esecuzione sono purtroppo lunghi, soprattutto aumentando la durata del video. Per il prototipo sviluppato nel corso di questo progetto, quindi, sono supportati video a 180p, con uno *scale factor* di 2, che corrisponde a un raddoppiamento dei fotogrammi per secondo del video, o a un rallentamento del 50%.

Potrebbero essere svolte ulteriori ottimizzazioni, che saranno trattate successivamente in questa relazione (vedi 3.2).

FONTI, METTERE POI IN BIBLIOGRAFIA

<https://pytorch.org/javadoc/1.9.0/>

<https://pytorch.org/mobile/home/>

# Capitolo 2

## Sviluppo Android

### 2.1 Funzionalità base

Per sviluppare l'applicazione Android è stato utilizzato Android Studio, che consente di sviluppare in linguaggio Java o Kotlin (consentendo anche di integrare librerie native in C/C++). Per questo progetto si è deciso di utilizzare Java.

Ogni applicazione Android è costituita da un insieme di *Activity*, ovvero oggetti che definiscono il comportamento dell'interfaccia utente. Queste Activity sono gli Entry Point dell'applicazione, rappresentano i meccanismi con i quali l'utente può avviare ed interagire con l'applicazione. Un altro concetto importante nell'ambito dello sviluppo Android è quello del *Lifecycle*. Ogni Activity segue un proprio ciclo vitale, e il suo comportamento può cambiare a seconda dello stato in cui si trova. Per questo motivo ciascuna Activity mette a disposizione dei metodi di callback da invocare quando l'Activity transiziona in uno stato particolare del suo Lifecycle (metodi `onCreate()`, `onPause()`, etc).

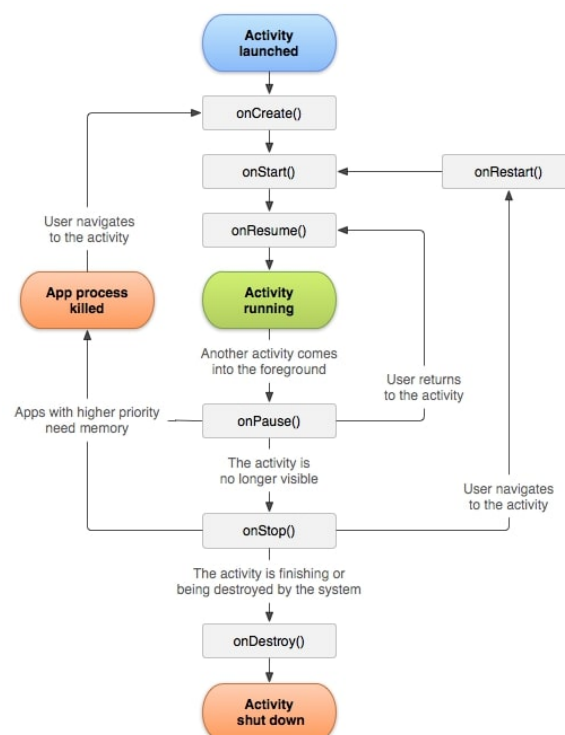


Figura 2.1: Schema del ciclo vitale di un'activity.

Fonte: <https://developer.android.com/guide/components/activities/activity-lifecycle>

Poiché l'applicazione mira alla creazione di video in slow-motion mediante l'interpolazione dei frame, operazione che verrà svolta in seguito alla cattura del video, distinguiamo due funzionalità principali: **cattura** del video ed **elaborazione** del video.

## Cattura del video

Activity di riferimento: `CatturaActivity.java`

Per la cattura del video si è fatto affidamento sulle api **CameraX** di Android, che consentono di utilizzare la fotocamera del dispositivo tramite un'interfaccia di alto livello.

CameraX definisce quattro *Use cases*, ciascuno dei quali rappresenta un possibile utilizzo della fotocamera ed è concretizzato da una classe Java:

- **Preview**: per mostrare un'immagine (o un video) sul display
- **Image analysis**: per applicare vari tipi di algoritmi sulle immagini acquisite
- **Image capture**: per catturare immagini
- **Video capture**: per catturare video (con audio)

Per la cattura del video, quindi, si è deciso di combinare una Preview con un Video Capture, in modo da dare la possibilità all'utente di catturare un video e mostrarne nel frattempo la preview.

Per utilizzare la fotocamera con le api CameraX, è intanto necessario ottenere un oggetto di tipo `ProcessCameraProvider`, ovvero l'istanza della fotocamera. Vediamo di seguito il codice utilizzato per ottenere l'istanza della fotocamera.

```
provider = ProcessCameraProvider.getInstance(this);
provider.addListener(() ->
{
    try {
        ProcessCameraProvider cameraProvider = provider.get();
        startCamera(cameraProvider);
    } catch (Exception e) {
        e.printStackTrace();
    }
}, getExecutor());
```

Si noti che il metodo `getInstance` restituisce un oggetto di tipo `ListenableFuture`. Questo perché, per vari motivi, la fotocamera potrebbe essere attualmente non disponibile. È quindi necessario specificare un listener che verrà invocato nel momento in cui la fotocamera si sarà resa disponibile.

Per poter esprimere le sue funzionalità, l'istanza della fotocamera richiede di essere collegata ad un *LifecycleOwner*, ovvero un qualsiasi oggetto che possieda un ciclo vitale. In questo modo lo stato della fotocamera è vincolato allo stato del `LifecycleOwner`. Nel nostro caso il `LifecycleOwner` sarà l'activity su cui stiamo lavorando. La funzione `startCamera` all'interno del listener si occupa di vincolare l'istanza della fotocamera al `Lifecycle` dell'attività corrente e agli use case di cui abbiamo bisogno:

```
private void startCamera(ProcessCameraProvider cameraProvider) {
    cameraProvider.unbindAll();
    CameraSelector camSelector = new CameraSelector.Builder()
        .requireLensFacing(CameraSelector.LENS_FACING_BACK).build();

    Preview preview = new Preview.Builder().build();
    preview.setSurfaceProvider(pview.getSurfaceProvider());
```

```

        videoCapt = new VideoCapture.Builder().setVideoFrameRate(25)
            .setAudioChannelCount(0).build();

        cameraProvider.bindToLifecycle((LifecycleOwner) this, camSelector,
            preview, videoCapt);
    }

```

A questo punto, è possibile utilizzare i controlli della cattura video tramite i metodi `videoCapture.startRecording()` e `videoCapture.stopRecording()`

## Elaborazione del video

Activity di riferimento: `SlomoActivity.java`

L'elaborazione del video, come già anticipato, viene affidata al modello Pytorch descritto nel capitolo precedente.

L'elaborazione è computazionalmente pesante e può richiedere tempi di esecuzione di diversi minuti: nei test svolti, un video di 2 secondi impiegava circa 5 minuti per essere elaborato. Per questo motivo si è deciso di delegare ad un *Worker* lo svolgimento dell'elaborazione. Ciò consente di disaccoppiare l'elaborazione dal ciclo vitale dell'activity, eseguendola in parallelo. In questo modo è possibile consentire all'elaborazione di proseguire anche quando l'utente porta l'activity in background per utilizzare altre applicazioni. Questo aiuta a mitigare i tempi di attesa.

## WorkManager

La classe *Worker* fa parte dell'API *WorkManager*, ovvero l'API raccomandata per il processamento in background su Android. All'interno della classe *Worker*, e in particolare nel metodo `doWork`, è possibile definire il comportamento dell'elaborazione che verrà eseguita in background. È stata quindi utilizzata una classe *SlomoWorker* che estende *Worker*.

Per inizializzare un *Worker* e far partire l'esecuzione in background, è necessario prima creare una *WorkRequest*, che può contenere un input da passare all'istanza del *Worker*. Nel nostro caso, l'unico input che viene passato allo *SlomoWorker* è il nome del video da processare.

```

// Creates WorkRequest, passing videoName as input data
slomoWorkRequest = new OneTimeWorkRequest.Builder(SlomoWorker.class)
    .set inputData(new Data.Builder().putString(SlomoWorker.VIDEO_NAME,
        videoName).build()).build();

```

Per mantenere notificato l'utente dello stato dei progressi dell'elaborazione, si è deciso di introdurre una *ProgressBar* nell'activity. Inoltre, poiché l'elaborazione può richiedere svariati minuti, si è deciso di utilizzare una notifica Android, anch'essa contenente una *ProgressBar*. Durante l'elaborazione, il *Worker* si occupa di notificare i propri progressi ai componenti in ascolto. È quindi necessario definire una funzione di callback che venga eseguita quando il worker progredisce nell'elaborazione, notificandolo opportunamente.

```

WorkManager.getInstance(getApplicationContext())
    .getWorkInfoByIdLiveData(slomoWorkRequest.getId())
    .observeForever(new Observer<WorkInfo>() {
        @Override
        public void onChanged(WorkInfo workInfo) {
            float progress = workInfo.getProgress()
                .getFloat(SlomoWorker.PROGRESS_TAG, 0);
            // gestisce le informazioni ricevute dal worker,
            // aggiornando gli elementi della UI

```

```

        // tra cui le due ProgressBar

        //...

        // Remove the observer when not needed anymore
        // 'this' = observer
        WorkManager.getInstance(getApplicationContext())
            .getWorkInfoByIdLiveData(sloMoWorkRequest.getId())
            .removeObserver(this);
    }
}

```

A questo punto possiamo accodare la `WorkRequest` tra le richieste di lavoro da eseguire:

```

// Enqueues sloMoWorkRequest
WorkManager.getInstance(this).enqueueUniqueWork(
    "superSloMoEvaluation",
    ExistingWorkPolicy.KEEP,
    sloMoWorkRequest);

```

La classe `SlomoWorker` di fatto è poco più che un wrapper per la classe `SlowMo`, descritta nel capitolo precedente. Inizialmente, esegue qualche elaborazione preliminare:

- Recupera il nome del video passato come input
- Recupera i frame estratti dal video
- Crea un oggetto di tipo `SlowMo`

Infine, invoca il metodo `doEvaluation()` sull'oggetto `SlowMo`, facendo partire di fatto l'elaborazione da parte del modello.

## 2.2 Conversione video

L'applicazione necessita di un metodo per convertire i video in immagini contenenti i fotogrammi, e viceversa convertire le immagini in video una volta finita l'elaborazione. Si è scelto di usare `Ffmpeg`, la più diffusa software suite di elaborazione media.

### FFmpeg

`FFmpeg` è il framework multimedia più diffuso sul mercato. Offre la possibilità di convertire, registrare, e riprodurre la maggior parte dei formati video e audio. In particolare, **FFmpeg** vero e proprio è la suite di conversione, encoding, e decoding di file multimediali, nella forma di un programma da linea di comando estremamente flessibile. **FFplay** è un media player basato sulle stesse librerie, e **FFprobe** è un programma per l'analisi di stream multimediali. Nella maggior parte dei casi, quando si parla di `FFmpeg` si intende il programma di conversione di file multimediali.

`FFmpeg` è gratuito e open source, ed è usato come backend di molte applicazioni di elaborazione media, sia mobile che desktop. Supporta la maggior parte dei sistemi operativi, tramite librerie ufficiali o create da utenti terzi, e in particolare, per lo scopo di questo progetto, anche Android.

Diverse librerie costituiscono la base di `FFmpeg`. Le più importanti per la funzione di conversione sono *libavcodec*, contenente decoder e encoder per molti codec audio e video, e *libavformat*, contenente *muxer* e *demuxer* (multiplexer e demultiplexer, per l'unione o separazione di canali multimedia) di vari formati media.

L'uso del programma da linea di comando è il seguente: vengono specificati uno o più file di input, uno o più file di output, e eventuali filtri e parametri opzionali. Per esempio:

```
-- Conversione tra formati audio
ffmpeg -i audioin.wav audioout.mp3
-- Estrazione di fotogrammi come immagini PNG
ffmpeg -i videoin.mp4 frames/%06d.png
-- Uso di filtri video per scalare e ruotare l'immagine, e altri parametri
ffmpeg -i videoin.mp4 -vsync 0 -vf "transpose=1,scale=-1:180" frames/%06d.png
```

In questo progetto, FFmpeg è stato usato per estrarre i fotogrammi come immagini PNG dal video di input, e unire i fotogrammi elaborati da Super SlowMo in un video con gli stessi fotogrammi per secondo dell'originale, e durata quindi raddoppiata.

## FFmpegKit

Per poter usare FFmpeg su Android, è stata usata la libreria FFmpegKit, che include strumenti per eseguire FFmpeg su Android, insieme ad altre piattaforme: iOS, macOS, tvOS, Flutter, e React Native. Offre diversi script per fare build delle librerie di FFmpeg, e una libreria wrapper per lanciare i comandi di FFmpeg e FFprobe all'interno delle applicazioni.

Per il contesto di questo progetto, FFmpegKit è stata usata per lanciare i comandi di FFmpeg all'interno dell'applicazione. Per questo scopo, offre una classe FFmpegKit, che può essere usata in questo modo, usando come esempio uno dei comandi mostrati sopra:

```
FFmpegSession session = FFmpegKit.execute("-i videoin.mp4 frames/%06d.png");
if (ReturnCode.isSuccess(session.getReturnCode())) {
    Log.i("App", "Extraction success");
} else if (ReturnCode.isCancel(session.getReturnCode())) {
    Log.i("App", "Extraction canceled");
} else {
    Log.d("App", String.format("Extraction failed with state %s and rc %s.%s", session.getState(), session.getReturnCode(), session.getFailStackTrace()));
}
```

L'istanza di FFmpegSession offre diversi metodi per ottenere informazioni sulla sessione in corso, specie nel caso in cui sia creata lanciando il comando in modo asincrono. Per esempio, questo codice permette di cancellare l'operazione dopo 5 secondi se non ancora conclusa:

```
FFmpegSession session = FFmpegKit.executeAsync("-i videoin.mp4 -vsync 0 -vf \"transpose=1,scale=-1:180\" frames/%06d.png"),
    new FFmpegSessionCompleteCallback() {
        @Override
        public void apply(FFmpegSession session) {
            ReturnCode returnCode = session.getReturnCode();
            Log.i("App", String.format("Extraction success with return code %s", returnCode));
        }
    });
Thread.sleep(5000);
if (session.getState() != SessionState.COMPLETED)
    session.cancel();
```

La libreria viene inclusa all'interno del progetto semplicemente aggiungendola a *build.gradle*:

```
dependencies {
    [...]
    implementation 'com.arthenica:ffmpeg-kit-full:4.5.1-1'
}
```

## ConvertVideo

Per semplificare l'uso di FFmpegKit nel contesto dell'applicazione, e ridurre il rischio di errori, comandi mal formati, o parametri dimenticati, è stata realizzata un'ulteriore classe **ConvertVideo**, che fa da wrapper a FFmpegKit per aggiungere parametri tramite metodi specifici, senza costruire manualmente la stringa del comando.

Un esempio di uso per estrarre fotogrammi, scalarli a 180p, e ruotarli (supponendo quindi un video verticale di partenza), è il seguente:

```
convertVideo.rotateClockwise();
convertVideo.setResize(320, 180);
boolean convertSuccess = convertVideo.extractFrames(
    selectedFile,
    extractedFramesDir.getAbsolutePath()
);
```

che è equivalente a

```
ffmpeg -i $selectedFile -vsync 0 -vf "transpose=1,scale=320:180"
    $extractedFramesDir/%06d.png
```

Questo assicura di evitare errori nell'impostazione dei parametri a livello di compilatore, che altrimenti non sarebbero notati fino al tempo di esecuzione data la loro collocazione dentro ad una stringa.

La classe offre un metodo per estrarre fotogrammi da un video:

```
extractFrames(inVideoPath, outFramesDir)
```

e un metodo per unire dei fotogrammi in un video:

```
createVideo(inFramesDir, outVideoPath, fps)
```

Offre inoltre alcuni metodi per impostare il ridimensionamento dell'immagine, e la trasposizione, cioè la rotazione, oltre che metodi per resettare alle impostazioni originali:

```
setResize(int width, int height)
resetResize()
rotateClockwise()
rotateCounterClockwise()
resetRotate()
```

La classe viene quindi usata prima e dopo l'elaborazione tramite la classe **SlowMo**, per estrarre i fotogrammi dal video di input e creare il video di output a partire dai fotogrammi elaborati.

## 2.3 Coordinazione tra processi e activity

Per riassumere e aggiungere qualche dettaglio, l'applicazione è così strutturata:

- **MainActivity**, contenente un menù di scelta che può avviare:
  - **CatturaActivity**, che si occupa della cattura del video
  - **SlomoActivity**, che si occupa dell'elaborazione del video tramite il modello Pytorch

La MainActivity è la finestra principale dell'app, mostrata all'avvio, e consente di scegliere quale operazione svolgere tra cattura video ed elaborazione. La scelta di una delle due operazioni si traduce in un passaggio ad una nuova finestra utente ovvero in un cambio Activity. Questo viene realizzato molto semplicemente tramite degli Intent:

```

private void showElabora(){
    Intent intent = new Intent(this, SlomoActivity.class);
    startActivity(intent);
}

private void showCattura(){
    Intent intent = new Intent(this, CatturaActivity.class);
    startActivity(intent);
}

```

L'activity di cattura è piuttosto semplice, non necessita di processi in background ed è dunque costituita dal solo Thread della UI. La fotocamera viene agganciata al ciclo vitale dell'Activity come già descritto.

La SlomoActivity, al contrario, fa uso di uno SlomoWorker per realizzare l'elaborazione del video mediante il modello Pytorch. Questa elaborazione viene eseguita concorrentemente agli eventi della UI, ma produce eventi che vanno a modificare gli elementi della stessa UI (in particolare le ProgressBar).

L'evento che ci interessa segnalare, in relazione al progresso dell'elaborazione video, è l'avvenuta elaborazione di un frame. Per gestire l'aggiornamento della UI a seguito di tale evento, si è deciso di utilizzare un modello simil *Publisher-Subscriber*. A questo scopo è stata creata un'interfaccia *IProgressHandler*:

```

public interface IProgressHandler {
    void publishProgress(float progress);
    void publishProgress(float progress, String message);
}

```

Questa viene concretizzata nella classe *SlomoWorkerProgressHandler*. Questa classe si occupa di realizzare la logica di notifica dei progressi alla UI. Per fare questo, si sfruttano due metodi messi a disposizione appositamente dalla classe Worker: *setProgressAsync()* e *setForegroundAsync()*:

```

public void publishProgress(float progress) {
    worker.setProgressAsync(new Data.Builder().putFloat(progress_tag,
        progress).build());
    worker.setForegroundAsync(createForegroundInfo(progress));
}

```

Il metodo *setProgressAsync()* consente di inviare progressi ad un qualsiasi Listener in ascolto sul Worker, incapsulati in un oggetto Data (in questo caso contenente solo un float). Come visto nella prima sezione di questo capitolo, il Listener dello SlomoWorker viene assegnato nella SlomoActivity, e si occupa di aggiornare la ProgressBar. Il metodo *setForegroundAsync()*, invece, invia un segnale al sistema Android e consente di aggiornare una notifica esistente o crearne una nuova. Tramite il metodo *createForegroundInfo()* ci occupiamo di creare un descrittore della notifica:

```

protected ForegroundInfo createForegroundInfo(@NonNull float progress) {
    // Build or Update a notification with progress bar

    //...

    Notification notification = new NotificationCompat.Builder(context,
        context.getString(R.string.notification_channel_id))
        .setContentTitle(title)
        .setTicker(title)
        .setSmallIcon(R.mipmap.ic_launcher_round)
        .setOngoing(true)
        .setOnlyAlertOnce(true)
        .setVisibility(NotificationCompat.VISIBILITY_PUBLIC)
}

```



```

        .setProgress(100, (int)(progress * 100), false)
        .addAction(android.R.drawable.ic_delete, cancel, intent)
        .build();

    return new ForegroundInfo(context.getResources()
        .getInteger(R.integer.notification_id), notification);
}

```

Un oggetto SlomoWorkerProgressHandler, così composto, viene passato dallo SlomoWorker all'oggetto SlowMo, in modo da consentire a quest'ultimo di pubblicare i propri progressi al termine dell'elaborazione di ciascun frame:

```

// SlowMo.java

public synchronized void doEvaluation() {
    //...

    for (Pair<Tensor, Tensor> sample : videoFrames) {
        //...

        // progressIncrements = 1 / (float)numVideoFrames;
        progress += Math.min(progressIncrements, 1f);

        if(progressHandler != null){
            progressHandler.publishProgress(progress);
        }
    }
}

```

— inserire magari qualche screen dell'applicazione per mostrare i punti chiave —

FONTI (METTERE IN BIBLIOGRAFIA)

<https://ffmpeg.org/> <https://github.com/tanersener/ffmpeg-kit>

# Capitolo 3

## Conclusioni e sviluppi futuri

### 3.1 Conclusioni

I maggiori punti di criticità del progetto risiedevano, come prevedibile, nell'utilizzo della rete neurale su dispositivo Android. La conversione del modello Pytorch originale ad un modello utilizzabile su Android ha richiesto la reimplementazione di alcune componenti software data la complessità del modello.

Altro punto critico è stata la coordinazione e comunicazione tra i diversi processi in gioco nell'applicazione, dovendo integrare la valutazione eseguita dalla rete neurale con un'interfaccia grafica il più possibile user-friendly. Come accennato brevemente, i test svolti sull'applicazione hanno dato luogo a tempi di elaborazione di 5 minuti per video di durata pari a 2 secondi. Questo tempo di elaborazione viene reso più tollerabile dall'esecuzione in background del modello, che consente all'utente di utilizzare altre applicazioni o di bloccare il dispositivo nell'attesa.

### 3.2 Sviluppi futuri

Aumento risoluzione, forse anche tramite server.

Aggiungere un collegamento diretto tra cattura del video ed elaborazione, senza doverlo rielezionare dalla galleria.

Sarebbe possibile svolgere l'interpolazione dei frame *in parallelo* alla cattura del video? Ovvero: la cattura video salva ogni frame sequenzialmente, i frame vengono intercettati dalla CNN che svolge l'interpolazione "on the fly" (molto complicato a fronte di un vantaggio minimo, contando che la cattura dura pochi secondi, avrebbe senso per video molto lunghi ma in ogni caso il tempo di elaborazione è  $\gg$  del tempo di cattura).